

Analiza popularnosti glazbe na Spotifyu

Kontekst problema

- **Tko je klijent?** → Studio d.o.o.
- **Problem:** Produksijske odluke o produkciji pjesama donose se "na osjećaj" umjesto temelja na podacima
- **Pitanje koje projekt pokušava odgovoriti:** Koje audio karakteristike koreliraju s visokom popularnošću pjesme? Cilj je maksimizirati popularnost klijenta.
- **Kratki opis dataseta:** 114.000 Spotify pjesama, 114 žanrova, 18+ audio značajki po pjesmi, popularnost 0–100


Dataset i prva istraživanja

- **Izvor:** Hugging Face (<https://huggingface.co/datasets/maharshipandya/spotify-tracks-dataset>)
- **Glavni stupci za kasniju analizu:**
track_genre, popularity, danceability, energy, explicit
- **Odmah uočeno:** višestruki izvođači po pjesmi (; separator),
duplikati po track_id (ista pjesma u više žanrova), rijetke null
vrijednosti

Čišćenje i relacijski model

- **Koraci čišćenja:**
 1. **drop** unnamed stupaca
 2. **normalizacija naziva** stupaca
 3. **explicit** → **bool**
 4. **klanjanje potpunih duplikata** (ne i track_id duplikata)
- **Split dataseta:** 80% za rad, 20% za ETL
- **Definiran ER model** — entiteti PJESMA, IZVOĐAČ, ALBUM, ŽANR
- **Veze:** Žanr 1:M Pjesma, Album 1:M Pjesma, Izvođač M:M Pjesma (razrješeno asocijativnom tablicom)
- Uvoz u MySQL (studio_data baza)


ER dijagram



Pretvorba u dimenzijski model

- **Zašto Star Schema:** analitički upiti, agregacije po dimenzijama
- **Fact tablica:** **star_fact_popularnost** — mjere: popularity, duration_ms, explicit
- **Dimenzije:**
 1. **star_dim_zanr** — zanr_grupa (7 grupa: Pop, Urban/R&B, Rock/Metal, Chill/Acoustic...)
 2. **star_dim_izvodjac** — vremenska dimezija (valid_from, valid_to, is_current)
 3. **star_dim_album** — velicina_albuma
 4. **star_dim_audio_catchy** — danceability, valence, energy, liveness → izvedene kategorije
 5. **star_dim_audio_technical** — loudness, tempo, key, mode, acousticness

Star Schema



ETL Proces

- **Stack:** Apache Spark (PySpark) + MySQL + Python
- **3 ETL Faze:**
 1. **Extract:** iz MySQL (studio_data relacijska baza) + CSV backup (80 + 20 split)
 2. **Transform:** pipeline s dimenzijskim transformacijama (zanr_grupa, catchy_karakter, energy_segment, tempo_band...)
 3. **Load:** u star schema tablice redom (dimenzije → fact), verifikacija NULL surogatnih ključeva

Ciljevi analize


Žanrovi, specs pjesama i njihova popularnost

- **Top žanrovi** po prosječnoj popularnosti
- **Usporedba žanr grupa** (Pop vs Urban/R&B vs Rock/Metal vs Chill/Acoustic)
- **Duljina pjesme** po omjeru popularnosti
- **Technical vs Catchy** karakteristike
- **NSFW vs SFW** pjesme
- ***Ključni nalaz: koje pjesme su najpopularnije i kakve su im karakteristike***


Rezultati analize

Popularnost žanrova


Popularnost žanr grupa



SFW vs NSFW





TOP 15 Najpopularnijih žanrova





Rezultati analize

Audio značajke i popularnost 1



Rezultati analize

Audio značajke i popularnost 2



Preopruke za studio

- **Singlovi su popularniji** od albuma
- **NSWF (18+) pjesme jesu popularnije** ali razlika nije velika
- **Izbjegavati “mirne” pjesme**
- **Mali danceability == mala popularnost!**
- **Pop je generalno najbolji izbor zbog:**
 1. **Najboljeg omjera popularnosti i danceability-a** (klubovi)
 2. **Prosječno trajanje pjesme**
 3. **Najsigurniji izbor**
 4. **Market nije prepravljen** (samo 7.8% pjesama od 90 000 su Pop)

Hvala na pažnji.